PCA antes do clustering

Escolha do número de componentes, desenho experimental e divisão de tarefas

Trabalho final de Aprendizado Não Supervisionado · versão de 09/11/2026 · rascunho para discussão com o professor

1. Pergunta de pesquisa

> Reduzir a dimensão com PCA antes de um algoritmo de clustering **melhora, piora ou é indiferente** para a qualidade dos clusters? Uma **regra sem rótulos** para escolher o número de componentes d (usar $d = K$, o número de clusters estimado pelo algoritmo, ou critérios de ruído como a borda de Marchenko-Pastur e a análise paralela) **acerta o *d* de melhor desempenho de um sweep completo**? E como isso muda com **p/n**, e a partir de qual p/n o método quebra?

Notação adotada (no quadro, a letra K aparece com dois sentidos; aqui eles ficam separados):

Símbolo	Significado
n, p, p/n	número de amostras, número de variáveis (dimensão original) e a razão entre eles
d	número de componentes do PCA, ou seja, a dimensão reduzida (no quadro: X reduzido, K×1)
K	número de clusters dado (por exemplo, 10 no MNIST e no digits)
K estimado	número de clusters que o próprio algoritmo calcula (no quadro: K~ no espaço reduzido)

2. Hipóteses

	Hipótese	Como testar
H1	O d indicado pela regra ($d = K$, Marchenko-Pastur com σ^2 estimado ou análise paralela) fica próximo do melhor d do sweep, e mais perto dele que os baselines simples (90% da variância, Kaiser).	Comparar o desempenho no d de cada regra com o máximo da curva do sweep, no conjunto de teste, com repetições.
H2	O d ótimo e o d das regras diminuem quando p/n aumenta.	Subamostrar n (p/n de 0,01 a acima de 1) e repetir o sweep.
H3	O efeito do PCA depende do algoritmo (K-means, GMM; KNN como sonda da informação preservada).	Uma curva de desempenho por algoritmo, com os mesmos dados.
H4	O PCA reduz o overfitting com muitas dimensões: a diferença entre treino e teste cai ao reduzir d.	Padronizador e PCA ajustados só no treino; medir a diferença treino–teste por d.
H5	Existe um p/n a partir do qual a regra deixa de acertar o d ótimo (o método quebra).	Medir a perda da regra em relação ao melhor d em função de p/n e definir o ponto de quebra.

Extensões, se sobrar tempo: a versão recursiva do procedimento (reaplicar a regra sobre os dados já reduzidos) e outras reduções de dimensão além do PCA (projeção aleatória, autoencoder, UMAP).

3. Notas da conversa com o professor, organizadas por tema

As anotações abaixo mantêm a redação original e estão agrupadas por tema. A nota de procedimento foi acrescentada depois, e a figura reproduz o desenho feito pelo professor no quadro.

3.1 Pergunta central

- Fazer um sweep de todas as componentes e ir avaliando se tem algum ponto que tem uma melhora.
- Esse ponto de melhora é o “K” calculado do nosso algoritmo e é ele que melhora?

- Calcular o sweep e ver se o K calculado fica próximo dele ou não.

3.2 Desenho experimental

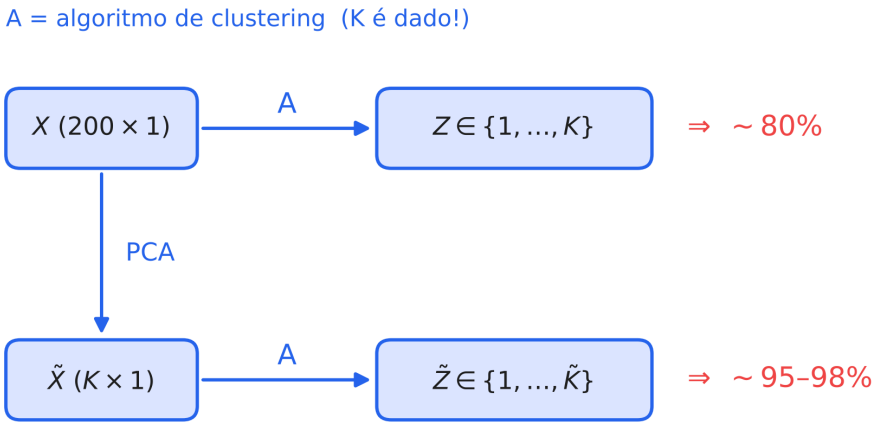


Figura 1. Esquema do quadro, redesenhado no Excalidraw. O algoritmo de clustering A (com K dado) leva X (200×1) a Z em {1,...,K}, com acurácia em torno de 80%. O PCA leva X a X reduzido (K×1), e o mesmo A leva a Z reduzido em {1,...,K~}, com acurácia maior, em torno de 95–98%. Os percentuais em vermelho estão pouco legíveis na foto do quadro, então valem como ordem de grandeza.

Procedimento (nota do Fred): “criar um algoritmo de clustering que calcula um K e define clusters. Pegar um dataset com certo p/n, fazer os clusters e guardar. Passar um PCA com K componentes (o mesmo K calculado pelo algoritmo) e rodar o mesmo algoritmo nesse PCA, avaliando como a performance melhorou em relação ao cluster original. Em paralelo, fazer um sweep de todos os K possíveis de PCA, rodar o clustering em cada um, achar a quantidade de componentes com melhor performance e avaliar se o método de usar o K de fato acerta essa melhor performance.”

- Treino x teste.
- Melhora, piora ou indiferente.
- Testar com diferentes p/n.
- Testar se diferentes p/n vão funcionando e em um ponto “quebra”.
- PCA é o menor das duas dimensões (o número de componentes vai até min(n−1, p)).

Regras candidatas para escolher *d* (todas sem rótulos, exceto a referência):

Regra	O que faz	Usa rótulos?
d = K (ou K−1)	usa o número de clusters; Ding e He indicam K−1 componentes para K clusters	não
Marchenko-Pastur	conta os autovalores acima de $\sigma^2(1+\sqrt{(p/n)})^2$, com σ^2 estimado pela mediana dos autovalores	não
Análise paralela	conta os autovalores acima do percentil 95 de dados embaralhados por coluna	não
90% da variância	menor *d* que acumula 90% da variância	não
Kaiser	autovalores maiores que 1 (dados padronizados)	não
Sweep completo	melhor *d* medido contra os rótulos, usado como referência	sim

Pontos de atenção

- O K estimado pelo algoritmo é instável e depende de *d*: no *digits*, o BIC escolheu entre 5 e 16 e a silhouette entre 8 e 15, contra os 10 reais. Testar a regra com K verdadeiro e com K estimado.
- “Em relação ao cluster original” mede concordância entre dois clusterings, não qualidade. O ARI contra os rótulos continua necessário.
- Ajustar o padronizador e o PCA só no treino (no piloto ajustamos com todos os dados, o que deve ser corrigido).

3.3 Avaliação

- Não tem problema usar um MNIST pra métricas.
- Diferentes métricas a depender do problema/aplicação.

Métrica	Para que serve
ARI e NMI contra os rótulos	qualidade do clustering; o rótulo entra só como régua, o algoritmo nunca o vê
Acurácia do KNN (validação cruzada)	sonda da informação útil preservada pela redução
Erro de reconstrução	quanto o PCA perde, sem clustering e sem rótulos (soma dos autovalores descartados)
Concordância com o clustering original	quanto os clusters se mantêm; precisa de uma linha de base de estabilidade (duas sementes)

3.4 Justificativa

- Porque a viagem vale a pena, tem maneiras mais simples de fazer isso?

Resposta proposta: comparar sempre com alternativas simples (sem PCA, 90% da variância, Kaiser, cotovelo). O argumento a favor das regras de ruído é que elas não precisam de rótulos nem de testar todos os *d*.

3.5 Perguntas em aberto e extensões

- Se fizermos recursivo vamos convergir em um cluster por amostra ou um cluster pra todos ou realmente o ótimo?
- Reduz overfitting com muitas dimensões?
- Talvez pensar em outras maneiras de redução de dimensionalidade além do PCA.

4. Indícios preliminares (piloto no digits)

Resultados de um piloto exploratório: um dataset (n = 1.797, p = 61), 10 repetições na subamostragem, sem barras de erro e com PCA ajustado em todos os dados. Servem para orientar o desenho, não como conclusão.

Observação	Números
Regras de ruído no digits completo	Marchenko-Pastur com $\sigma^2 = 1$: 12 componentes; análise paralela: 16; Kaiser: 17; Marchenko-Pastur com σ^2 estimado (0,45): 24; 90% da variância: 31.
KNN	Com o *d* de Marchenko-Pastur (σ^2 estimado), a acurácia ficou a no máximo 0,006 da máxima nos cinco tamanhos de n. A análise paralela perdeu de 0,009 a 0,045, e Marchenko-Pastur com $\sigma^2 = 1$ perdeu de 0,042 a 0,064.
GMM	O PCA ajudou bastante (ARI de 0,36 sem PCA para 0,49 no melhor *d*, com n = 1.797), mas o melhor *d* foi pequeno (entre 4 e 12), abaixo do indicado pelas regras.
K-means	Curva praticamente plana a partir de $d \approx 8$ a 12 (ARI entre 0,46 e 0,53); o PCA ganhou no máximo 0,04 sobre os dados completos.
Regra d = K = 10	Perdeu entre 0,013 e 0,048 de ARI no K-means, entre 0,026 e 0,056 no GMM e entre 0,016 e 0,047 de acurácia no KNN em relação ao melhor *d*.
Recursão	Repetir a regra de ruído sobre os dados já reduzidos colapsou a dimensão: 61 → 24 → 8 → 4 → 1.

Sobre novidade. Antes de apresentar o trabalho como inédito, vale uma busca de literatura mais completa: há trabalhos próximos (Yeung e Ruzzo, Gavish e Donoho), e a busca feita até aqui foi curta.

5. Divisão de tarefas (5 pessoas)

As horas são estimativas, só de código; somar cerca de 3 h de leitura e 3 h de escrita por pessoa.

Pessoa	Tarefa	Horas	Leitura
P1	**Dados e infraestrutura:** digits, MNIST e dados sintéticos; split treino/teste; pré-processamento ajustado só no treino; subamostragem para variar p/n; funções de métrica (ARI, NMI, acurácia do KNN, reconstrução).	~7	Yeung e Ruzzo
P2	**Algoritmo de clustering que estima K:** K-means e GMM com escolha de K por BIC e silhouette, validado com K conhecido nos dados sintéticos; gera o clustering "original" em alta dimensão.	~8	Ding e He
P3	**Regras para *d*:** Marchenko-Pastur com σ^2 estimado, análise paralela, d = K (e K−1) e baselines (90%, Kaiser, cotovelo).	~7	Johnstone e Paul; Horn
P4	**Sweep e comparação:** clustering para cada *d*, curvas com repetições e barras de erro, classificação em melhora/piora/indiferente com margem, comparação do *d* de cada regra com o melhor *d*.	~9	Gavish e Donoho
P5	**p/n, overfitting e ponto de quebra:** p/n de 0,01 a acima de 1 com MNIST subamostrado; diferença treino–teste; definição do ponto de quebra.	~8	Murphy cap. 20.1; estudo sistemático recente

Ordem de trabalho. P1 monta a infraestrutura primeiro, mas P2 e P3 já podem desenvolver em paralelo usando o digits. P4 depende de P1 a P3, e P5 depende de P1 e P4.

Escrita. P5: Pergunta e Motivação. P1 a P3: Metodologia. P4 e P5: Resultados. Todos: Conclusões. As extensões (recursão e outras reduções) ficam para quem terminar primeiro.

Combinados. Definir cedo a assinatura das funções compartilhadas (o que a função de clustering recebe e devolve) e usar um repositório único com ambiente **uv**, para todos instalarem as mesmas versões.

6. Leituras

Trabalho	Papel no projeto	Acesso
Johnstone e Paul (2018), PCA in High Dimensions: An Orientation, *Proc. IEEE*	Teoria de quando o PCA separa sinal de ruído (modelo spiked, Marchenko-Pastur, transição BBP)	gratuito (PMC)
Ding e He (2004), K-means clustering via principal component analysis, ICML	Liga o PCA ao K-means; base da regra d = K−1	gratuito (ICML)
Horn (1965), A rationale and test for the number of factors in factor analysis, *Psychometrika*	Artigo original da análise paralela	Springer, provavelmente pago; alternativas gratuitas: slides e a documentação do pacote hornpa
Yeung e Ruzzo (2001), Principal component analysis for clustering gene expression data, *Bioinformatics*	Estudo empírico: o PCA antes do clustering nem sempre ajuda	gratuito
Gavish e Donoho (2014), The optimal hard threshold for singular values is 4/√3	Limiar de componentes com ruído desconhecido (estimado pela mediana) e razão de aspecto	gratuito (arXiv)
Murphy, *Probabilistic Machine Learning: An Introduction*, cap. 20.1 (PCA) e 21 (clustering)	Base de PCA, K-means e GMM	livro do grupo
Estudo sistemático sobre o impacto da redução de dimensão no clustering (arXiv 2604.22099, 2026)	Trabalho recente próximo do nosso; ainda não lido (vi só o título)	arXiv